2018.9.29

기계학습

정유진

Growth Hackers

CONTENTS

1. 머신러닝 기본개념

• 머신러닝(machine learning)이란???

개념 : 인공 지능을 구현하는 구체적 접근 방식

특징 : 1. AI로부터 파생

2. 기존 컴퓨터와 다른 새로운 능력을 포함

1. 머신러닝 기본개념

<전통적 컴퓨터> VS <머신러닝>

<전통적 컴퓨터>

규칙기반(rule based)의 접근법

- 사람이 직접 컴퓨터에게 지능적으로 행동하는 방법을 알려주고, 빠르게 그 행동을 처리하도록 함.

<머신러닝>

사람이 직접 생각하는 방법을 알려주는 것이 아니라 기계가 스스로 배우도록 하는 것.

- 컴퓨터로 알고리즘을 학습하여 새로운 데이터가 들어왔을 때 데이터 결과 예측.
- 미리 프로그램되지 않은 부분에서도 예측과 결정을 내릴 수 있는 방식

Growth Hackers

1. 머신러닝 기본개념

- 활용 예

1. **Database mining** ex) web click data, medical records
2. **Applications can't program by hand** ex) 자동헬리콥터, 손글씨 자동인식, NLP
3. **Self customizing system** ex) 아마존, 넷플릭스의 추천시스템
4. **Human learning 이해** ex) brain, real AI

- 참조

딥러닝 : 머신러닝의 일종으로 인공신경망에서 발전한 형태의 인공지능.
뇌의 뉴런과 유사한 정보 입출력 계층을 활용해 데이터를 학습

2. 모델 예시(지도 vs 비지도)

- **모델이란?**

다양한 변수 간의 수학적(or 확률적) 관계를 표현한 것
어떤 물리현상을 특정한 목적에 맞추어 이용하기 쉬운 형식으로 표현하는 일

- **지도학습**

데이터에 대한 레이블(명시적인 정답)이 주어진 상태에서 컴퓨터를 학습시키는 방법

- **비지도학습**

데이터에 대한 레이블(명시적인 정답)이 주어지지 않은 상태에서 컴퓨터를 학습시키는 방법론. 데이터 형태로 학습을 진행.

2. 모델 예시(지도 vs 비지도)

• 지도학습(supervised learning)

특정 타겟을 예측. 과거에 타겟 정보가 있는 데이터를 사용하여 모델 학습. 새로운 데이터를 활용하여 모델 평가

Regression	Classification
Output이 countinuous일 경우	Output이 discrete일 경우

• 비지도학습(unsupervised learning)

예측하고자 하는 타겟 변수 존재하지 않음. 데이터에 내재된 특성을 분석(데이터 분포 추정, 고객 집단 구분, 연관 규칙 분석).

Clustering	Non-Clustering : 독립성분분석
유사한 데이터를 묶는 것	Cocktail party problem : 목소리 구분

2. 모델 예시(지도 vs 비지도)

- **지도학습(supervised learning) 예시**

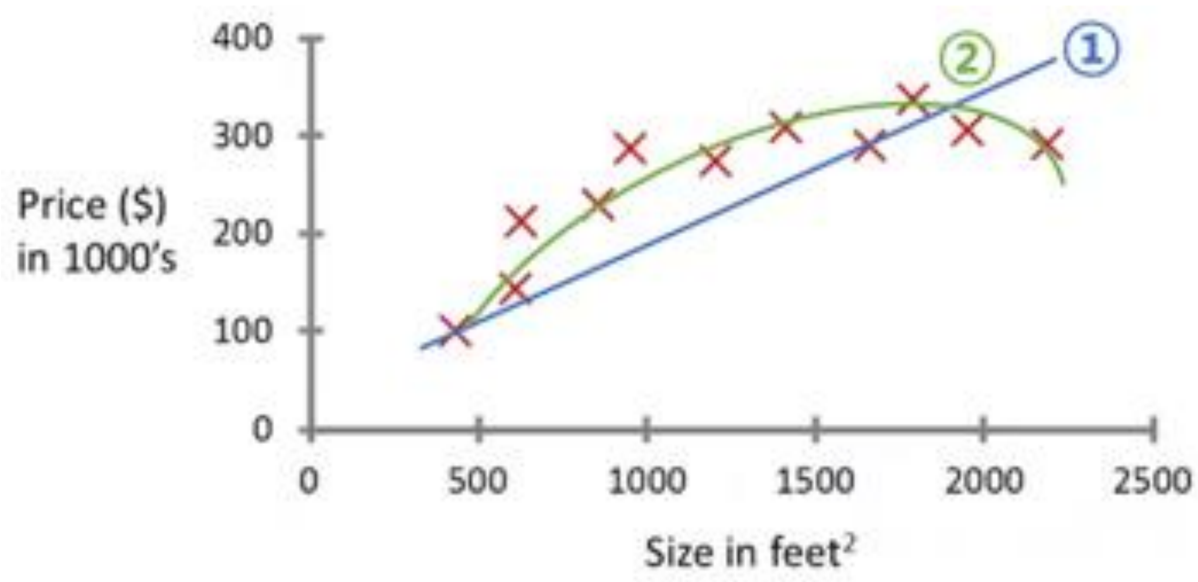

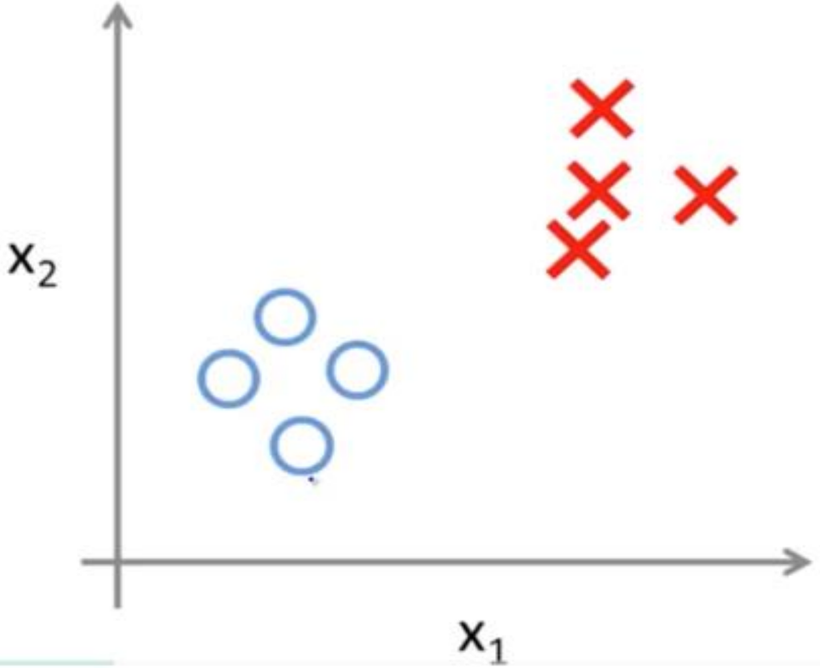

2. 모델 예시(지도 vs 비지도)

- **비지도학습(unsupervised learning) 예시**

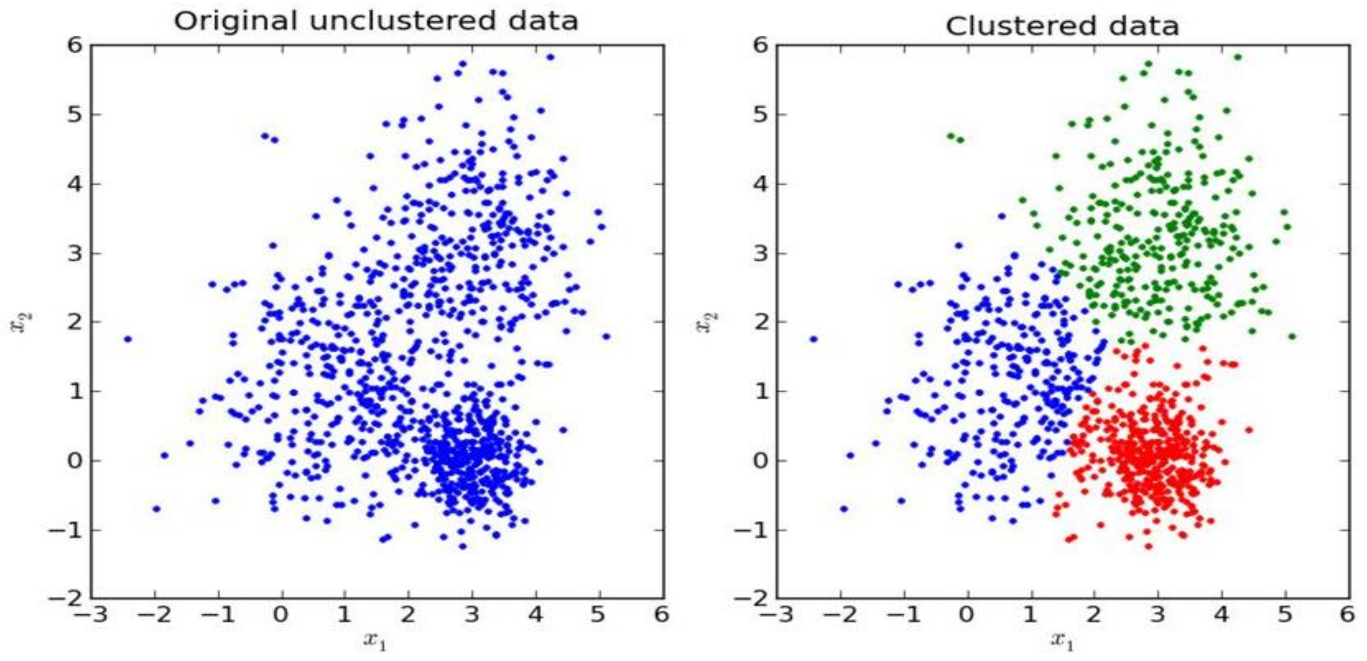

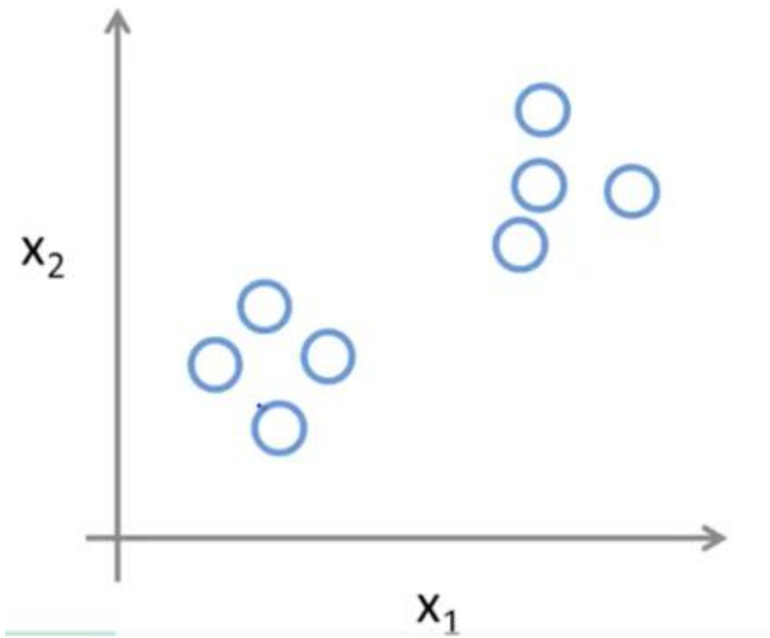

https://www.youtube.com/watch?v=T0HP9cxri0A

2. 모델 예시(지도 vs 비지도)

지도학습	Classification	kNN
		Naïve Bayes
		Support Vector machine
		Decision Tree
	Regression	Linear regression
		Locally weighted linear regression
		Ridge
		Lasso
비지도학습		Clustering
		K means
		Density estimation
		Expectation maximization
		Pazen window
		DBSCAN

3. 모델 평가방법

- **test-train split**

모델의 정확성을 검증하기 위하여 training set, validation set, test set으로 나눈다. (비율은 임의대로지만 대부분 7:3 or 6:2:2로 나눈다.)

Training set으로 학습시키고 test set으로 평가한다. Validation set으로 모델이 여러 개일 때 최종 모델을 선정하기 위한 성능 평가도 한다.

3. 모델 평가방법

- **test-train split**

```
def split_data(data, prob):
    results = [], []
    for row in data:
        results[0 if random.random() < prob else 1].append(row)
    return results
```

```
def train_test_split(x, y, test_pct):
    data = zip(x, y)      #Data를 두 종류로 나눔
    train, test = split_data(data, 1 - test_pct) #데이터 셋을 나눔
    x_train, y_train = zip(*train) #zip 풀기
    x_test, y_test = zip(*test)
    return x_train, x_test, y_train, y_test
```

```
model = SomeKindOfModel()
x_train, x_test, y_train, y_test = train_test_split(xs, ys, 0.33)
model.train(x_train, y_train)
performance = model.test(x_test, y_test)
```

3. 모델 평가방법

- **혼동행렬**

	실제 O	실제 X
분류 O	True Positive	False Positive
분류 X	False Negative	True Negative

예 : 스팸메일 분류

True Positive(TP) : 실제 스팸메일을 스팸메일로 분류

False Positive(FP) : 실제 스팸메일이 아니지만 스팸메일로 분류

False negative(FN) : 실제 스팸메일이지만 스팸이 아닌 것으로 분류

True negative(TN) : 실제 스팸메일이 아니고 스팸메일이 아니라 분류

3. 모델 평가방법

<정확성 지표>

1. 정확도

모델이 정확하게 양성 또는 음성으로 예측한 비율

(TP+TN)/Total

2. 정밀도(검정력)

모델이 양성으로 예측한 것 중 실제 양성인 비율

TP/(TP+FP)

3. 재현율

실제 양성인 것 중 실제 양성으로 정확히 예측한 비율

TP/(TP+FN)

4. F1점수

정밀도와 재현율의 조화평균, 항상 정밀도와 재현율 사이의 값을 가짐

2*p*r/(p+r)

Growth Hackers

3. 모델 평가방법

<정확성 지표 코드>

1. 정확도

```
def accuracy(tp, fp, fn, tn):
    correct = tp + tn
    total = tp + fp + fn + tn
    return correct / total

print(accuracy(70, 4930, 13930, 981070))
```

2. 정밀도(검정력)

```
def precision(tp, fp, fn, tn):
    return tp/ (tp + fp)

print(precision(70, 4930, 13930, 981070))
```

3. 재현율

```
def recall(tp, fp, fn, tn):
    return tp/ (tp + fn)

print(recall(80, 4930, 13930, 981070))
```

4. F1점수

```
def f1_score(tp, fp, fn, tn):
    p = precision(tp, fp, fn, tn)
    r = recall(tp, fp, fn, tn)

    return 2 * p * r / (p + r)
```

3. 모델 평가방법

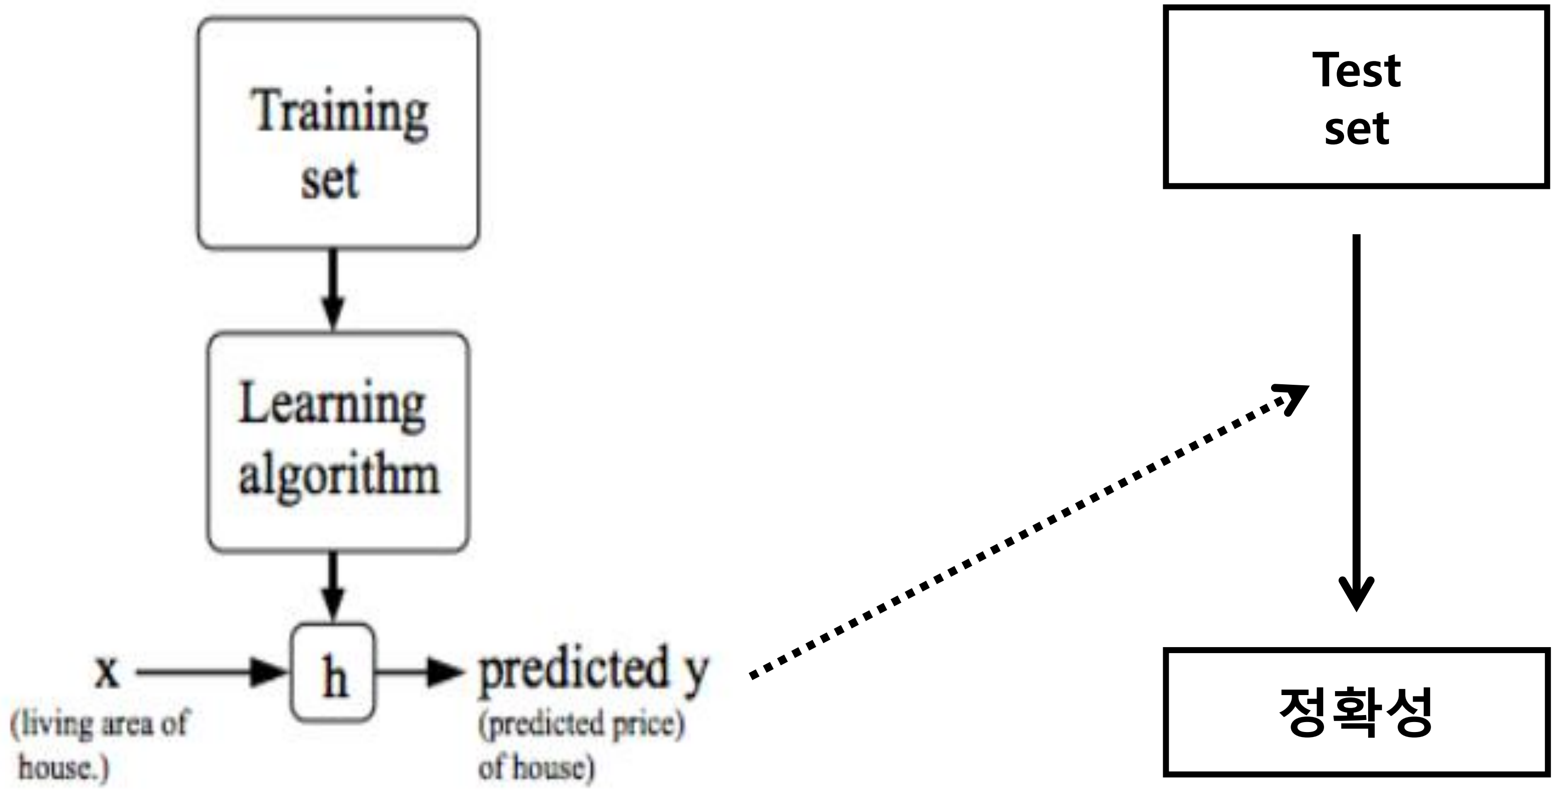

Growth Hackers

3. 모델 평가방법

- **Overfitting vs Underfitting**

Overfitting

모델의 성능이 학습데이터에는 좋지만, 새로운 데이터에 대해서는 좋지 않은 경우

Underfitting

모델의 성능이 학습데이터에도 좋지 않은 경우

Growth Hackers

3. 모델 평가방법

- **bias vs varience**

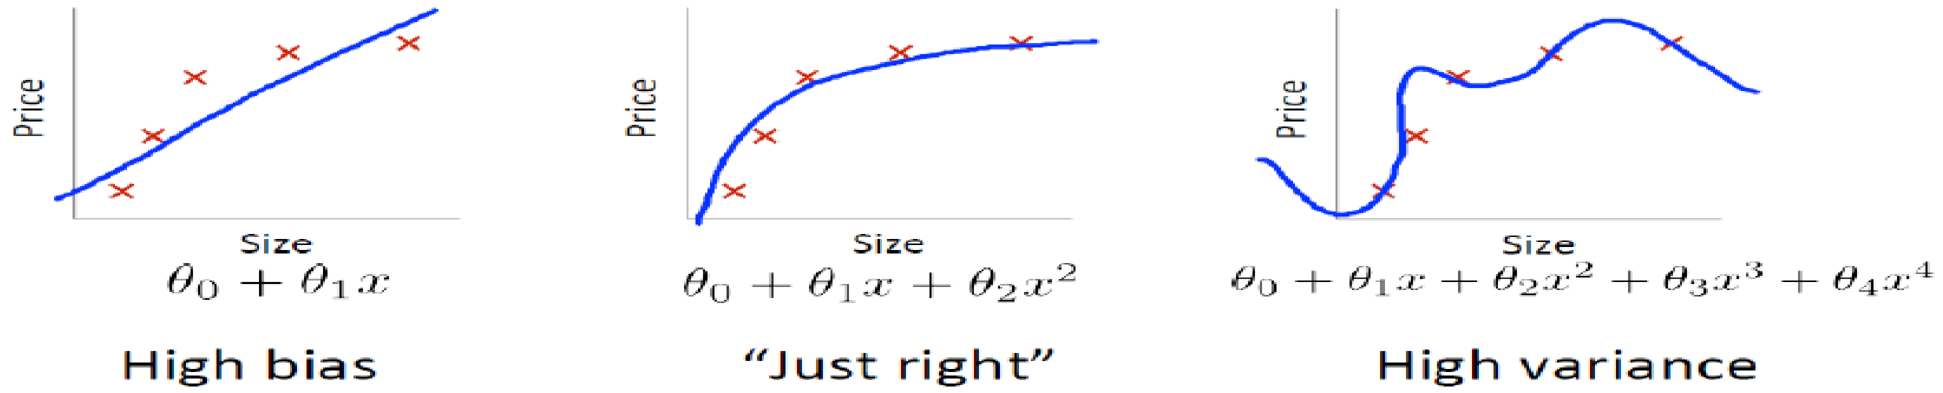

- **High bias**
  1. 새로운 feature 추가하기
  2. polynomial feature 추가하기

- **High variance**
  1. 학습데이터 양을 늘리기
  2. 쓸데없는 변수 줄이기

4. Hypothesis/Cost Function/Gradient Descent

- **가설(hypothesis)**

Input(feature)과 output(target)의 관계를 나타내는 함수

예 : $h_\theta(x) = \underline{\theta_0} + \underline{\theta_1} x$

parameters

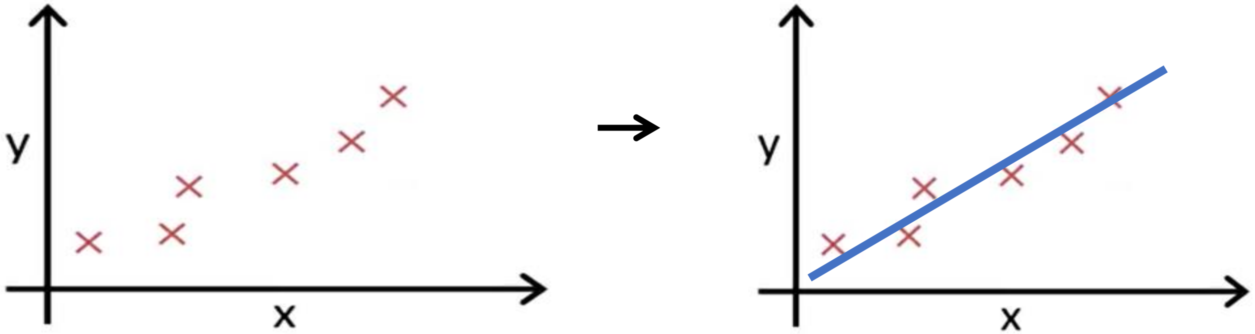

4. Hypothesis/Cost Function/Gradient Descent

실제 y와 예측 y와의 차이
$(y - \hat{y})$들을 줄여야 한다.

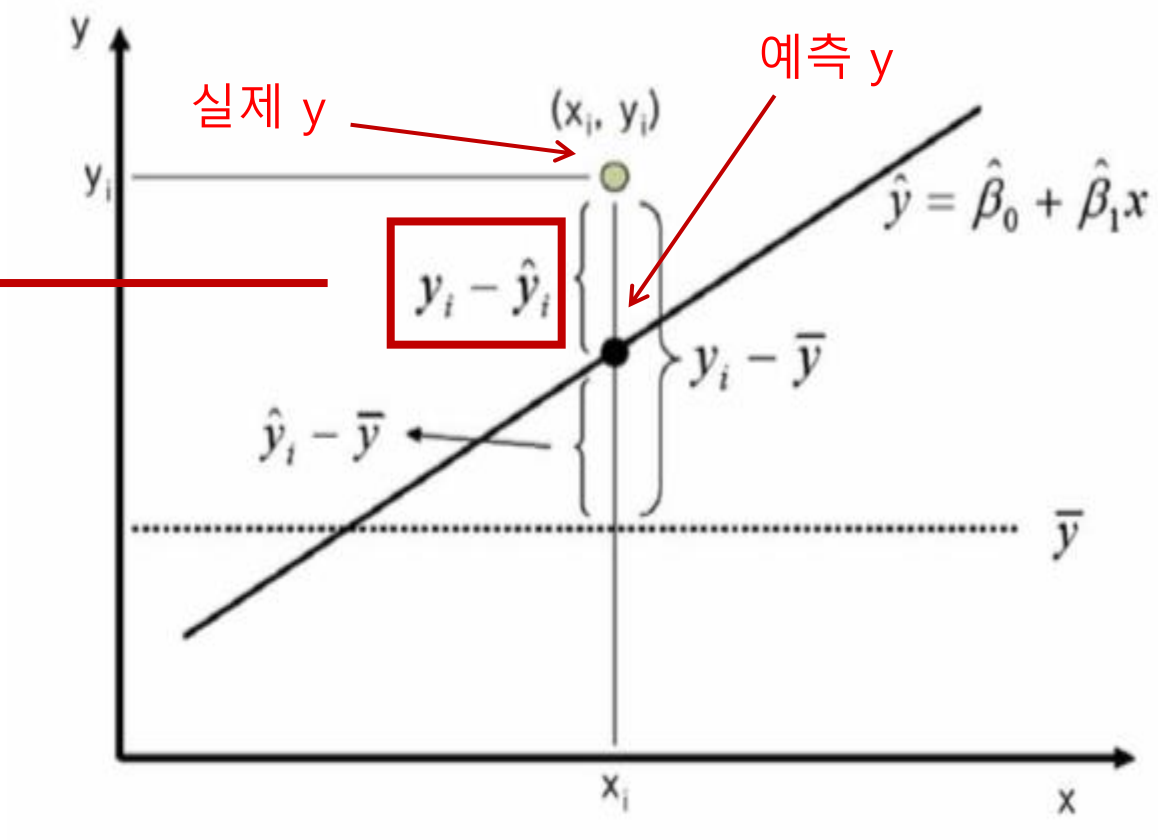

Growth Hackers

4. Hypothesis/Cost Function/Gradient Descent

- **Cost Function**

비용에 관련된 모든 변량에 대하여 어떤 관계를 나타내는 함수.
주어진 데이터에 가장 잘 '맞는' 직선을 선택하기 위한 일정 기준.
가설의 식의 정확성을 측정하기 위한 식.

$$J(\theta_0, \theta_1) = \frac{1}{2m}\sum_{i=1}^{m}((\underbrace{h_\theta\left(x^{(i)}\right)}_{\text{가설}} - \underbrace{y^{(i)}}_{\text{실제}}))^2 = \frac{1}{2m}\sum_{i=1}^{m}((\left(\hat{y}^{(i)}\right) - y^{(i)}))^2$$

4. Hypothesis/Cost Function/Gradient Descent

- **Cost Function**

$$J(\theta_0,\theta_1) = \frac{1}{2m}\sum_{i=1}^{m}((h_\theta(x^{(i)}) - y^{(i)}))^2 = \frac{1}{2m}\sum_{i=1}^{m}((\hat{y}^{(i)}) - y^{(i)}))^2$$

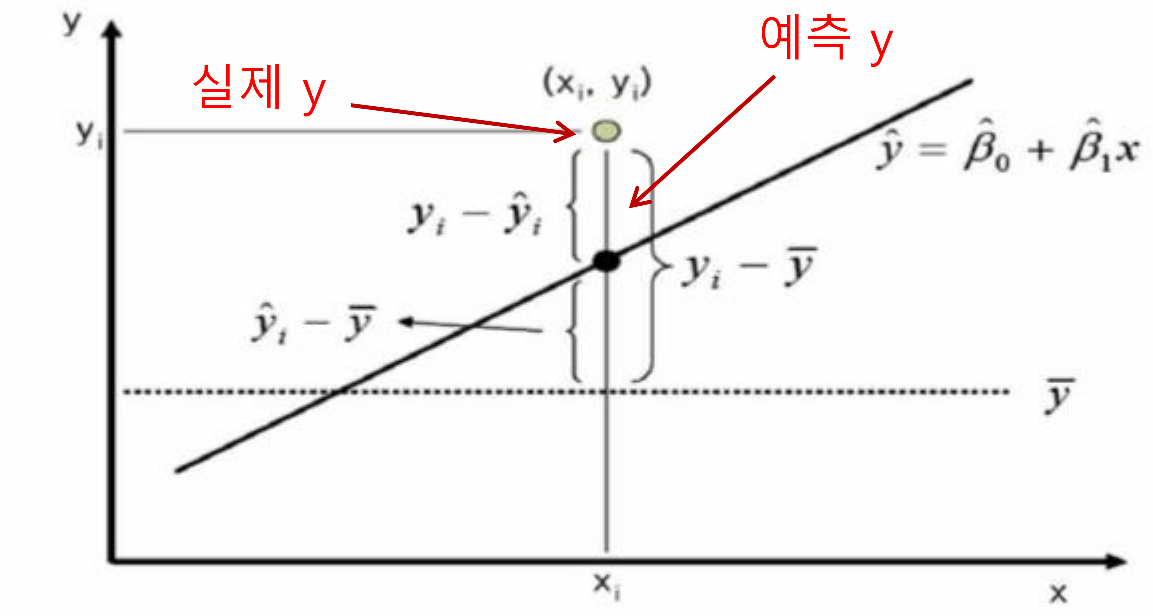

$$y_i - \bar{y} = (y_i - \hat{y}_i) + (\hat{y}_i - \bar{y})$$

$$\sum_{i=1}^{n}(y_i - \bar{y})^2 = \sum_{i=1}^{n}(y_i - \hat{y}_i)^2 + \sum_{i=1}^{n}(\hat{y}_i - \bar{y})^2$$

총제곱합	잔차제곱합	회귀제곱합	
SST	SSE	SSR	
$n-1$	$n-2$	1	(자유도)

*SST (Total sum of squares)

*SSR (Regression sum of squares)

4. Hypothesis/Cost Function/Gradient Descent

- **Gradient Descent**

Hypothesis function의 최적의 parameter을 찾는 방법

$$h_\theta(x) = \boxed{\theta_0} + \boxed{\theta_1} x$$

parameters

목표 : Cost Function에서 $J(\theta_0, \theta_1)$을 최소화 → $\min_{\theta_0,\theta_1} J(\theta_0, \theta_1)$

전략 : 1. 어떤 parameter에서든 시작 가능

2. 계속 이 parameter을 변화해가면서 최소의 J를 찾는 것

Growth Hackers

4. Hypothesis/Cost Function/Gradient Descent

- **Gradient Descent**

algorithm : $$\theta_j := \theta_j - \underbrace{\alpha}_{\text{Learning Rate (학습율)}} \underbrace{\frac{\partial}{\partial \theta_j} J(\theta_0, \theta_1)}_{\text{<derivative>}}$$

Learning Rate
(학습율)

<derivative>

<Update Rules>

$$\boxed{\begin{aligned} \theta_0 &:= \theta_0 - \alpha \frac{d}{d\theta_0} J(\theta_0, \theta_1) \\ \theta_1 &:= \theta_1 - \alpha \frac{d}{d\theta_1} J(\theta_0, \theta_1) \end{aligned}}$$

$$\frac{d}{d\theta_0} J(\theta_0, \theta_1) = \frac{1}{m} \sum_{i=1}^{m} (h_\theta(x^{(i)}) - y^{(i)})$$

$$\frac{d}{d\theta_1} J(\theta_0, \theta_1) = \frac{1}{m} \sum_{i=1}^{m} (h_\theta(x^{(i)}) - y^{(i)}) \cdot x^{(i)}$$

Growth Hackers

4. Hypothesis/Cost Function/Gradient Descent

- **Gradient Descent**

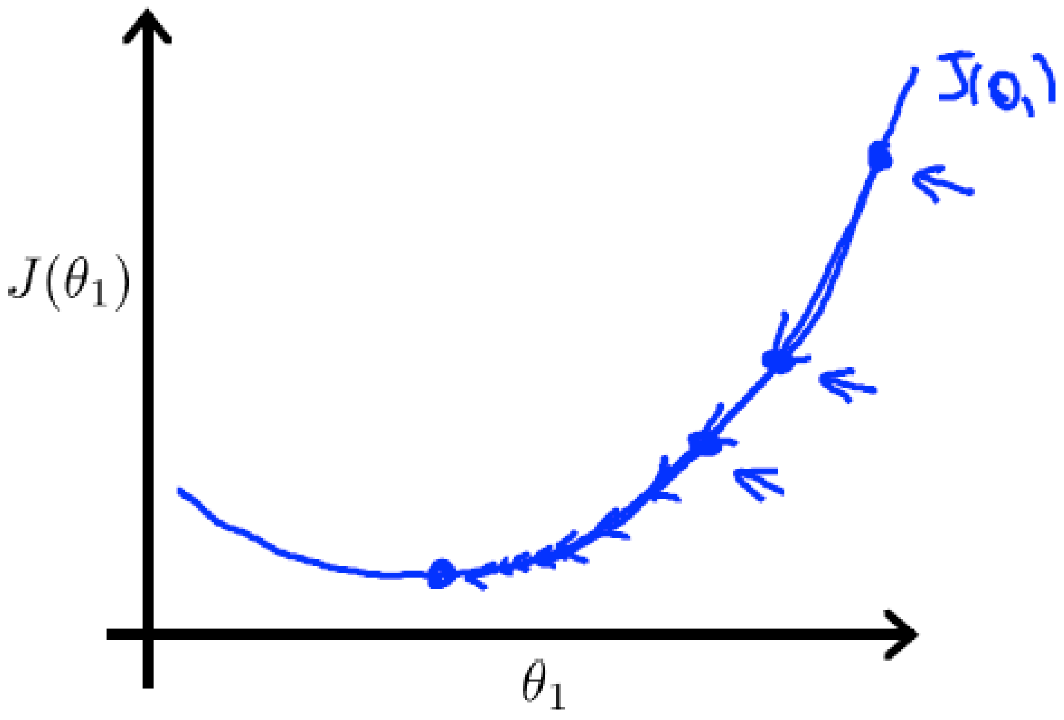

$$\theta_j := \theta_j - \alpha \frac{\partial}{\partial \theta_j} J(\theta_0, \theta_1)$$

학습율(learning rate)=α는 항상 양수

- Minimum<θ 일 경우 학습율이 적정 크기일 때, 미분 값(>0)이 점점 작아지며 θ가 왼쪽으로 향한다.
- Minimum>θ 일 경우 학습율이 적정 크기일 때, 미분 값(<0)이 점점 작아지며 θ가 오른쪽으로 향한다.

4. Hypothesis/Cost Function/Gradient Descent

$h_\theta(x)$

(for fixed θ_0, θ_1, this is a function of x)

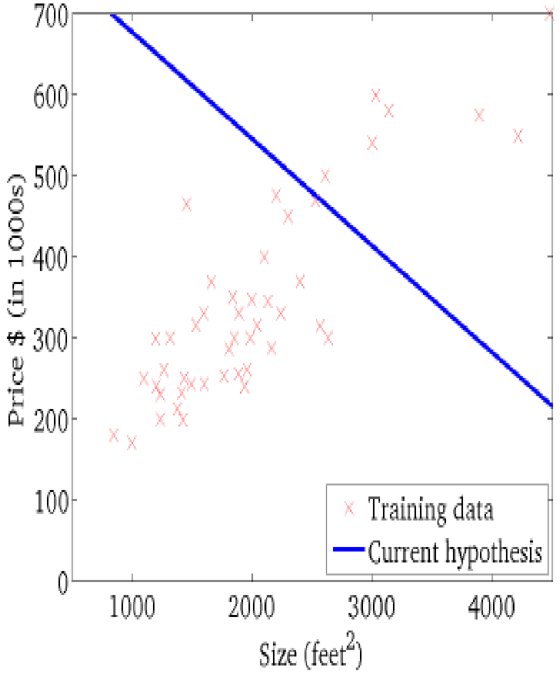

$J(\theta_0, \theta_1)$

(function of the parameters θ_0, θ_1)

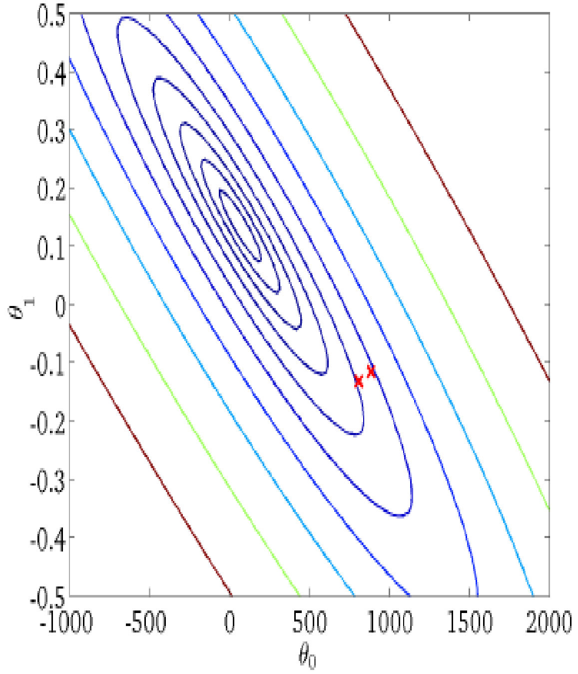

$h_\theta(x)$

(for fixed θ_0, θ_1, this is a function of x)

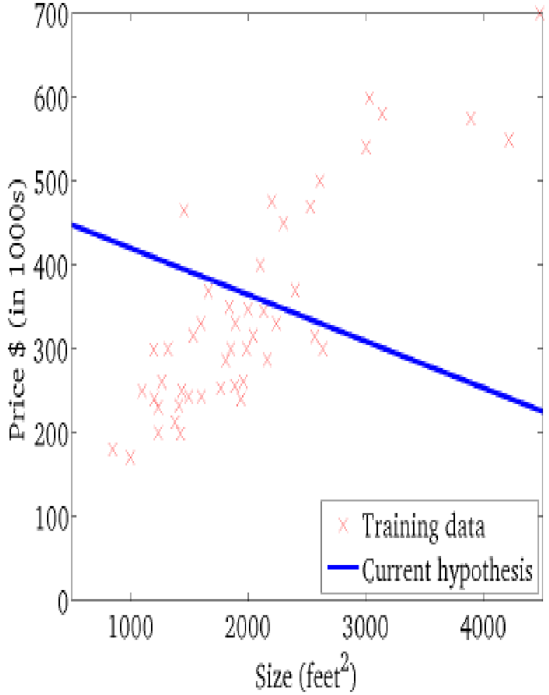

$J(\theta_0, \theta_1)$

(function of the parameters θ_0, θ_1)

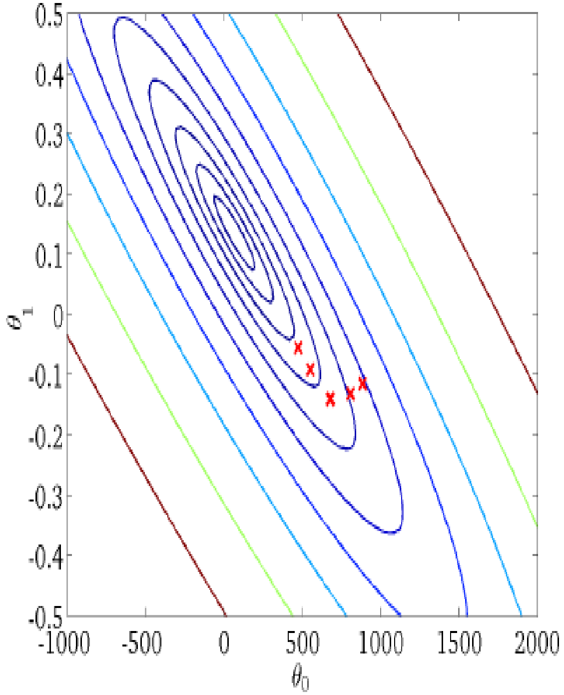

Growth Hackers

4. Hypothesis/Cost Function/Gradient Descent

$h_\theta(x)$

(for fixed θ_0, θ_1, this is a function of x)

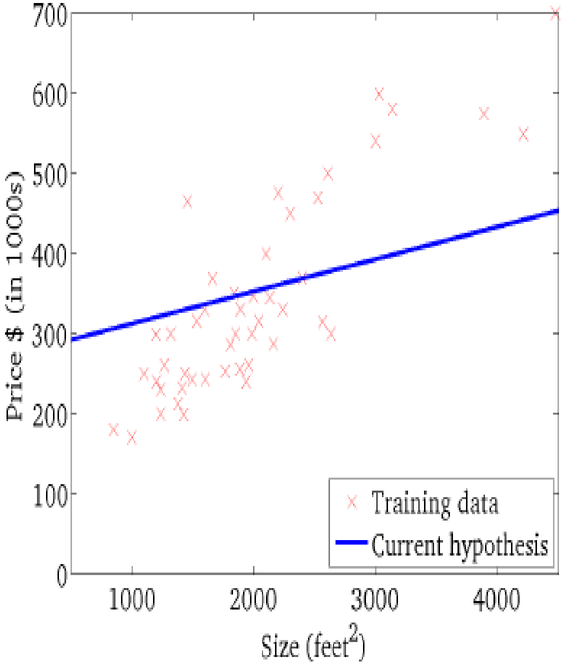

$J(\theta_0, \theta_1)$

(function of the parameters θ_0, θ_1)

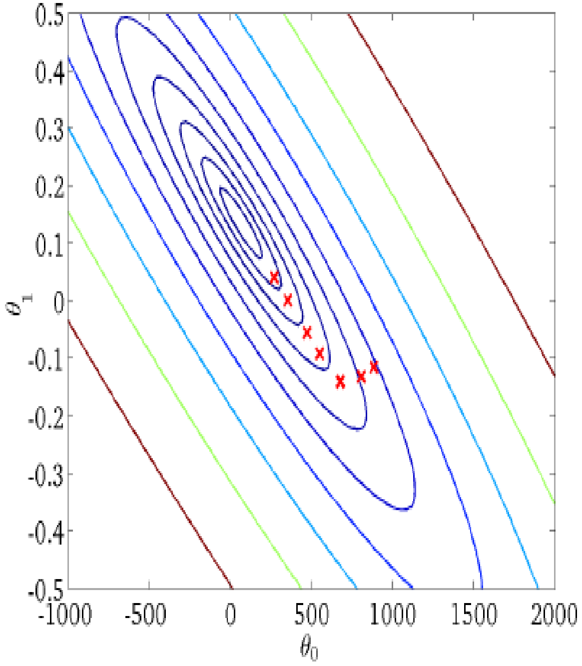

$h_\theta(x)$

(for fixed θ_0, θ_1, this is a function of x)

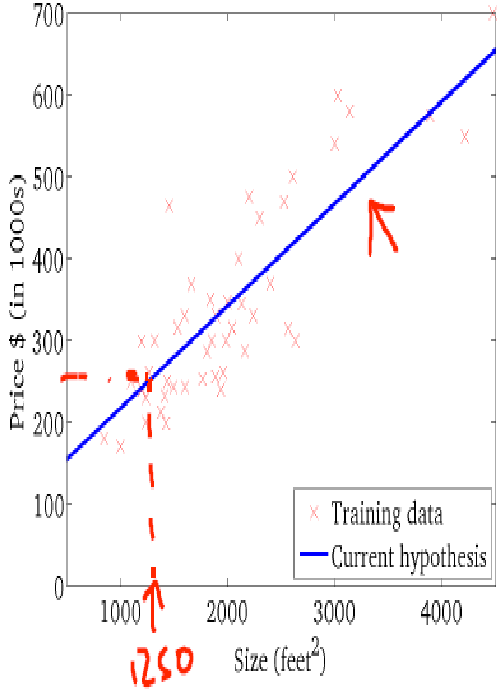

$J(\theta_0, \theta_1)$

(function of the parameters θ_0, θ_1)

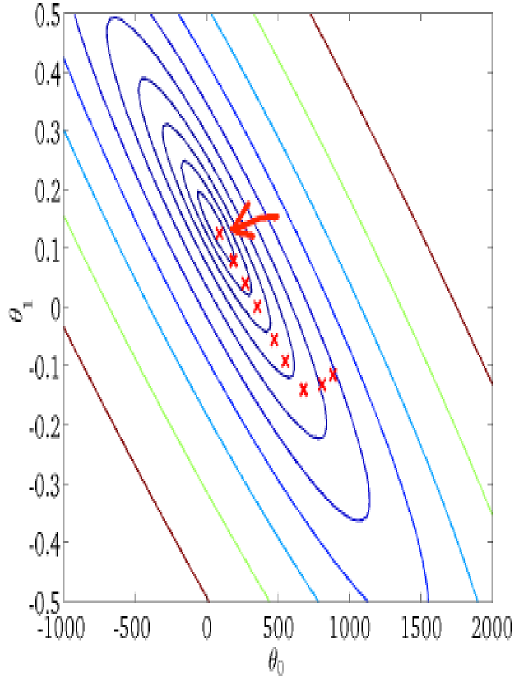

4. Hypothesis/Cost Function/Gradient Descent

- **Gradient Descent**

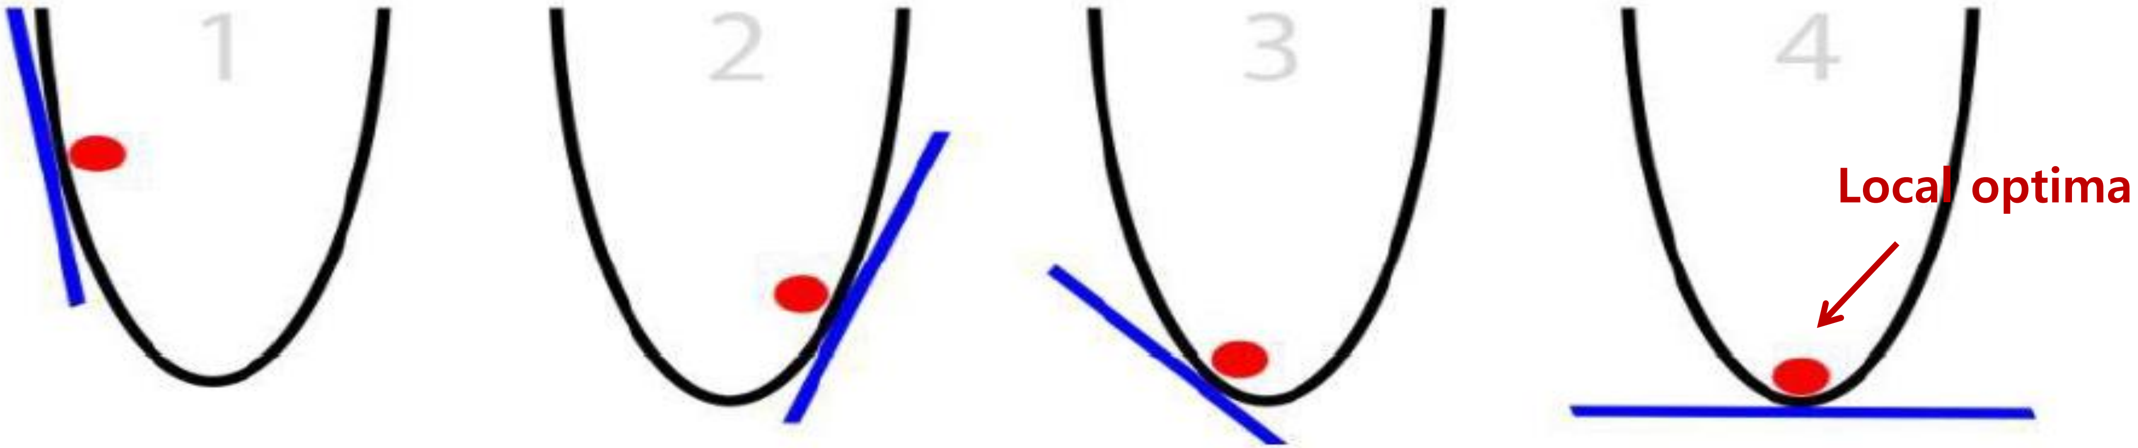

- α에 따라서 위치가 계속해서 바뀐다.
- Gradient descent가 local optima에 이르면 편미분항이 0이라 더이상 update되지 않는다.
- 최적값에 가까워질수록 편미분항의 크기와 gradient descent의 크기가 작아져 learning rate를 굳이 update하지 않아도 된다.

4. Hypothesis/Cost Function/Gradient Descent

- **Gradient Descent**

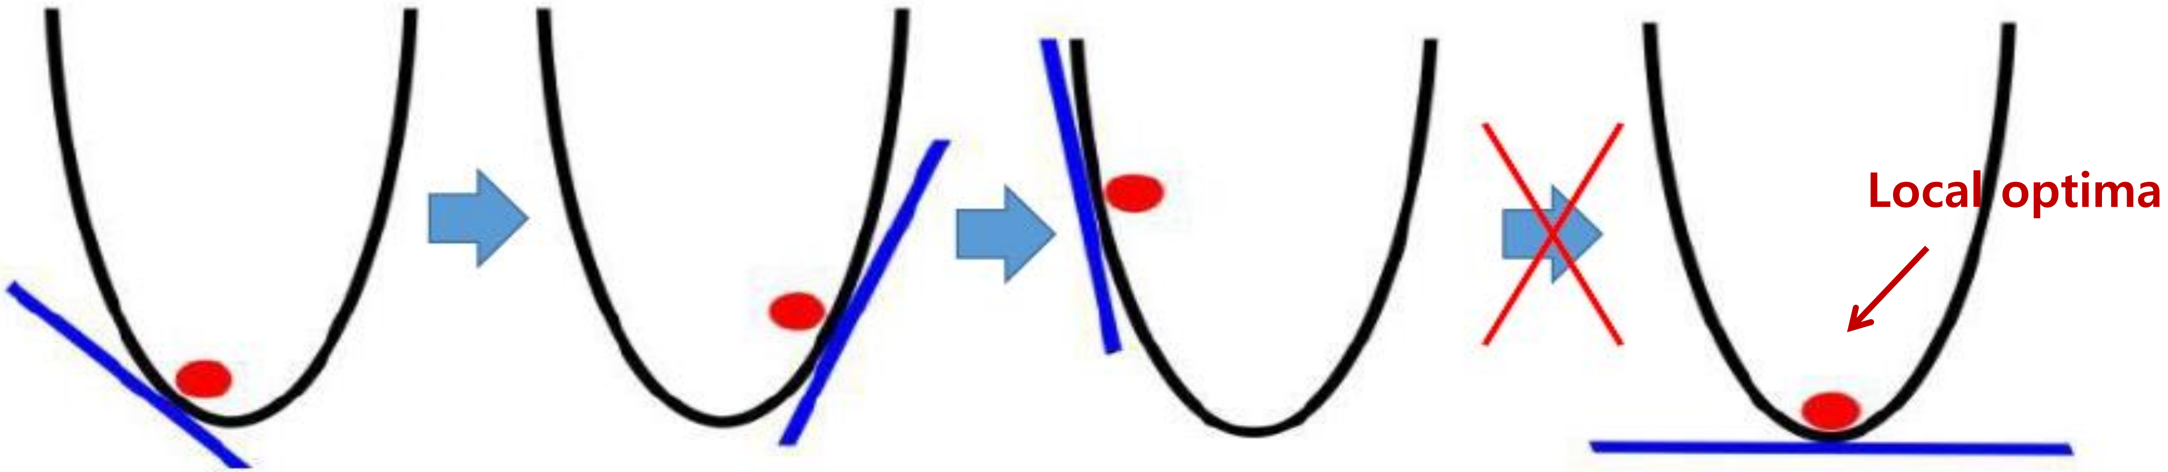

Q. 만약 learning rate(alpha)가 너무 크다면???

- 최적값에 가까워지지 않고 점점 최적값으로부터 멀어지게 update된다..
- 결국 최적값에 다다를 수 없게 된다.

4. Hypothesis/Cost Function/Gradient Descent

- **Normal Equation**

x_0	Size (feet²) x_1	Number of bedrooms x_2	Number of floors x_3	Age of home (years) x_4	Price ($1000) y
1	2104	5	1	45	460
1	1416	3	2	40	232
1	1534	3	2	30	315
1	852	2	1	36	178

$$X = \underbrace{\begin{bmatrix} 1 & 2104 & 5 & 1 & 45 \\ 1 & 1416 & 3 & 2 & 40 \\ 1 & 1534 & 3 & 2 & 30 \\ 1 & 852 & 2 & 1 & 36 \end{bmatrix}}_{m \times (n+1)} \qquad y = \underbrace{\begin{bmatrix} 460 \\ 232 \\ 315 \\ 178 \end{bmatrix}}_{m\text{-dimensional vector}}$$

$$\boxed{\theta = (X^T X)^{-1} X^T y}$$

Growth Hackers

4. Hypothesis/Cost Function/Gradient Descent

- **Normal Equation**

  Method to solve for θ analytically

$X\theta = y$를 완전히 만족하는 theta가 optimal. → $\therefore \theta = X^{-1}y$

But inverse of X가 존재하지 않을 때가 있음.

$$\boxed{\theta = (X^T X)^{-1} X^T y}$$

4. Hypothesis/Cost Function/Gradient Descent

- **Gradient Descent vs Normal Equation**

	Gradient Descent	Normal Equation
Learning Rate	필요	불필요
N이 클 때(약 n=10^6)	잘 작동	매우 느리다
Iteration	많이 필요	X

5. 코드

- **필요 모듈**

1. **Matplotlib** : matlab과 비슷한 인터페이스를 가진 라이브러리로 그래프를 그릴 수 있게 해준다.
2. **Numpy** : X변수 설정을 위해 필요하다

numpy.linspace

`numpy.linspace(start, stop, num=50, endpoint=True, retstep=False, dtype=None)` [source]

Return evenly spaced numbers over a specified interval.

Returns *num* evenly spaced samples, calculated over the interval [*start*, *stop*].

The endpoint of the interval can optionally be excluded.

```
xx = np.linspace(-10,10,501)
```

임의의 xx변수에 x값 할당해준다.
(-10,10)범위에서 같은 간격으로 500개 뽑아 x에 입력값의 범위를 설정해준다.

3. **Scipy** : 최저점을 찾게 해주는 모듈

scipy.optimize.minimize

`scipy.optimize.minimize(fun, x0, args=(), method=None, jac=None,`

5. 코드

- **1차원 함수-그래프 나타내기**

(x,y) 데이터 셋에서 Y=aX+b로 모델을 가정하였다.
Cost Function : (x-2)^2+2

```
from matplotlib import pyplot as plt
import numpy as np

#1변수 함수 정의
def f1(x):
    return (x-2)**2+2

xx=np.linspace(-10,10,501) #(-10,10)범위에서 같은 간격으로 500개 뽑아 점 찍기
plt.plot(xx,f1(xx),'k') #k는 선으로 있는 것, xx값에 x를 할당해서 f1 그래프 그리기
plt.xlim(-4,8) #x범위 (-4,8)범위
plt.ylim(0,40) #y범위 (0,40)범위
plt.show() #그래프 보여주기
```

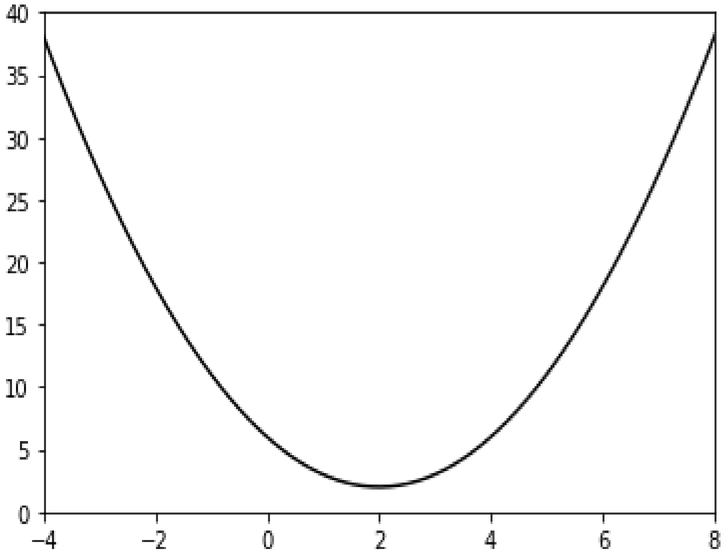

Growth Hackers

5. 코드

- **1차원 함수-Gradient Descent**

```
#f1을 미분한 함수 정의
def f1d(x):
    return 2*(x-2)

plt.plot(xx,f1(xx),'k')
alpha=0.4 #learning rate 설정
x=0 #초기값 설정
plt.plot(x,f1(x),'go',markersize=10) #go는 점을 찍으란 소리, 사이즈는 10

x=x-alpha*f1d(x) #gradient descent
plt.plot(x,f1(x),'go',markersize=10,color='r')#색깔은 red

x=x-alpha*f1d(x) #gradient descent
plt.plot(x,f1(x),'go',markersize=10,color='b')#색깔은 blue

plt.xlim(-2,6)
plt.ylim(0,20)
plt.show()
```

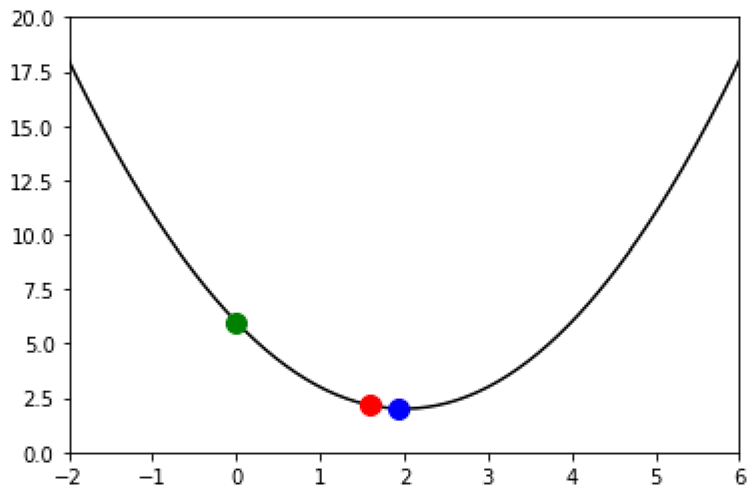

Growth Hackers

5. 코드

- **1차원 함수-Gradient Descent(learning rate가 크다면?)**

```
plt.plot(xx,f1(xx),'k')
alpha=1.2 #learning rate 설정
x=0 #초기값 설정
plt.plot(x,f1(x),'go',markersize=10) #go는 점을 찍으란 소리, 사이즈는 10

x=x-alpha*f1d(x) #gradient descent
plt.plot(x,f1(x),'go',markersize=10,color='r') #색깔은 red

x=x-alpha*f1d(x) #gradient descent
plt.plot(x,f1(x),'go',markersize=10,color='b') #색깔은 blue

plt.xlim(-2,6)
plt.ylim(0,20)
plt.show()
```

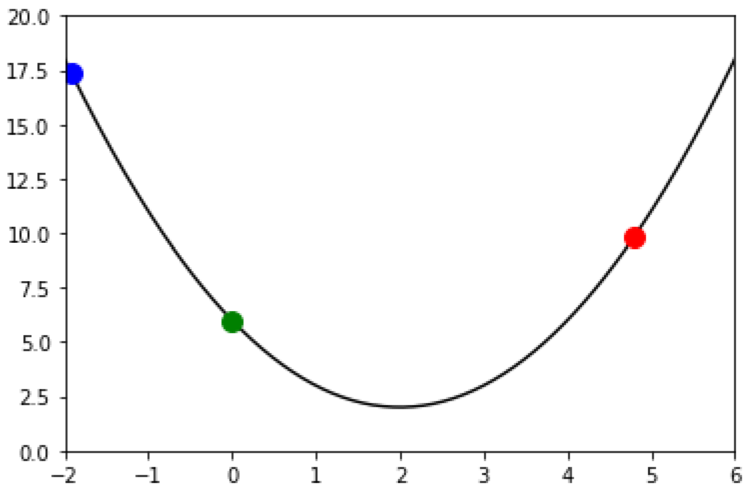

Growth Hackers

5. 코드

- **1차원 함수-Gradient Descent(if, while문)**

```
alpha=0.4
x=0

temp=x-alpha*f1d(x)

if (f1(temp)>f1(x)): #알파값이 너무 클 때 크다고 알려주는 메세지 나오게 하기
    print("learning rate is too large!")
else :
    while(True):
        temp=x-alpha*f1d(x)
        if ((temp-x)<0.005): #temp와 x의 차이가 매우 얼마나지 않을 때까지 실행
            break
        x=temp

print(x,f1(x))
```

```
1.9968 2.00001024
```

5. 코드

- 1차원 함수-scipy이용

```
from scipy import optimize as op #scipy모듈 불러오기
result=op.minimize(f1,1) #바로 알 수 있다.
print(result)
```

```
      fun: 2.0
 hess_inv: array([[0.5]])
      jac: array([0.])
  message: 'Optimization terminated successfully.'
     nfev: 9
      nit: 2
     njev: 3
   status: 0
  success: True
        x: array([1.99999999])
```

5. 코드

- ## 2차원 함수-그래프 그리기

(x,y,z) 데이터 셋에서 모델을 가정하였다.
Cost Function : (1-x)^2+100*((y-x^2)^2)

```
def f2(x,y):
    return (1-x)**2 +100*(y-x**2)**2

xx=np.linspace(-3,3,101)
yy=np.linspace(-3,3,101)
X,Y=np.meshgrid(xx,yy) #2차원함수 그리기 쉽도록 mershgrid이용(참조바람)
Z=f2(X,Y)

plt.contour(X,Y,Z,colors='gray',levels=[0.7,3,5,15,50,150,500,1500,5000]) #등고선 그리기
plt.show
```

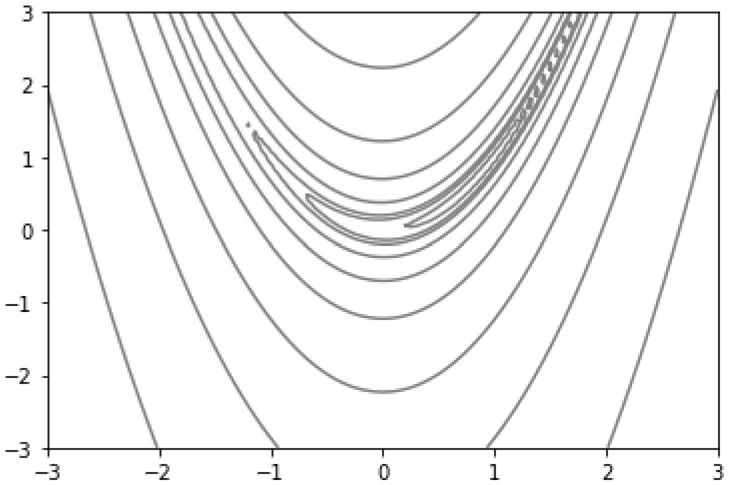

5. 코드

- **2차원 함수-Gradient Descent**

```
def f2d(x,y):
    return np.array([2*x-2-400*x*(y-x**2),200*(y-x**2)])
plt.contour(X,Y,Z,colors='gray',levels=[0.7,3,5,15,50,150,500,1500,5000])

alpha=8e-04
x=-2
y=-2
g=f2d(x,y)
print(g)

plt.plot(x,y,'go',markersize=10)

x=x-alpha*g[0]
y=y-alpha*g[1]
g=f2d(x,y)
plt.plot(x,y,'go',markersize=10,color='r')

x=x-alpha*g[0]
y=y-alpha*g[1]
g=f2d(x,y)
plt.plot(x,y,'go',markersize=10,color='b')

plt.show()
```

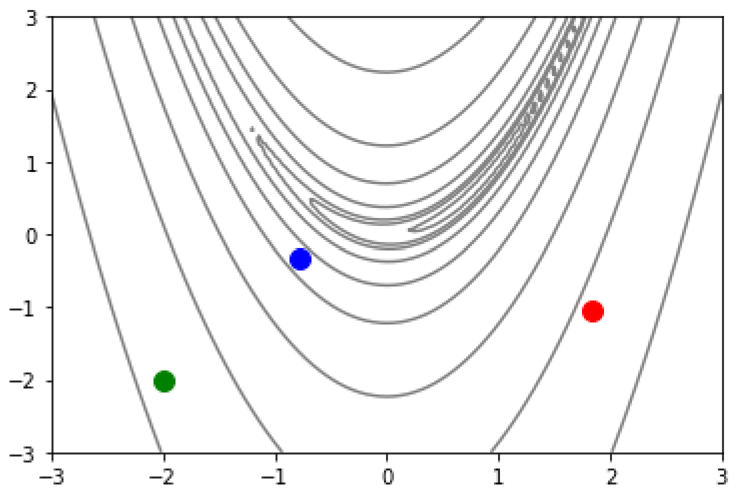

Growth Hackers

5. 코드

- **2차원 함수-Gradient Descent(if, while문)**

```
alpha=8e-04
x=-2
y=-2
g=f2d(x,y)

temp=(x-alpha*g[0],y-alpha*g[1])

if(f2(temp[0],temp[1])>f2(x,y)):
    print("learning rate is too large!")
else :
    while(True):
        g=f2d(x,y)
        temp=(x-alpha*g[0],y-alpha*g[1])
        if(f2(x,y)-f2(temp[0],temp[1])<0.00000000005):
            break
        x=temp[0]
        y=temp[1]

print(x,y,f2(x,y))
```

```
0.9997205483173297 0.9994400562865879 7.821833404464664e-08
```

5. 코드

- **2차원 함수-Gradient Descent(Scipy 이용)**

```python
def f3(x):
    return (1-x[0])**2 +100*(x[1]-x[0]**2)**2

result=op.minimize(f3,(2,2))
print(result)
```

```
      fun: 1.8932893809017893e-11
 hess_inv: array([[0.51675994, 1.03186494],
       [1.03186494, 2.0655726 ]])
      jac: array([ 5.27380711e-06, -2.50575298e-06])
  message: 'Optimization terminated successfully.'
     nfev: 140
      nit: 30
     njev: 35
   status: 0
  success: True
        x: array([0.99999565, 0.99999129])
```

Quest

‘caschool.csv’데이터에서 str과 avginc변수를 통해 read_scr을 예측할 수 있는 y=a*x1+b*x2+c 모형으로 Cost function을 minimize해보세요.